
Alterando BERT

Anonymous Author(s)

Affiliation

Address

email

1 Gabriel Santos Ferreira de Pádua
2 Universidade Federal de Viçosa
3 Florestal, MG 2026
4 gabriel.padua@ufv.br

Abstract

5 Este trabalho apresenta a evolução e o aprimoramento do ajuste fino *fine-tuning*
6 do modelo BERT_{BASE} para classificação de sentimentos no dataset SST-2 (GLUE).
7 Com o objetivo de otimizar o custo computacional e aumentar a capacidade de gen-
8 eralização, aplicou-se a técnica de congelamento de camadas (*Layer Freezing*), ina-
9 tivando a atualização de pesos nas 8 primeiras camadas do codificador. A avaliação
10 demonstrou um nítido *trade-off* entre eficiência e acurácia: a restrição arquitetural
11 com o conjunto original de 2.000 amostras reduziu o tempo de treinamento em
12 40%, sob o custo de uma queda de precisão para 84,17%. Contudo, ao explorar
13 a eficiência computacional gerada para expandir a coletânea de treinamento para
14 20.000 amostras, o modelo atingiu 90,60% de acurácia. Os resultados atestam que
15 o gerenciamento estratégico dos parâmetros treináveis viabiliza o aprendizado em
16 maior escala sob restrições severas de hardware, garantindo ganhos expressivos e
17 validação prática da técnica de transferência de aprendizado.

18 **Disponível em:** https://github.com/deyrik/Redes_Neurais

19 1 Introdução

20 O presente relatório consolida a fase final de avaliação do modelo BERT (*Bidirectional Encoder Rep-*
21 *resentations from Transformers*), dando continuidade à reprodução inicial (TPF-01) do experimento
22 de ajuste fino para classificação de sentimentos no dataset SST-2. O objetivo central desta etapa é
23 implementar modificações arquiteturais e experimentais para aprimorar o desempenho, aumentar a
24 capacidade de generalização e reduzir a complexidade computacional do treinamento.

25 2 Modificações e Justificativas

26 A estratégia primária adotada consistiu na aplicação da técnica de congelamento de camadas (*Layer*
27 *Freezing*), enquadrando-se em abordagens de transferência de aprendizado (*fine-tuning*). Na imple-
28 mentação original e no TPF-01, todos os 110 milhões de parâmetros das 12 camadas do modelo
29 base foram atualizados simultaneamente. Nesta nova configuração (denominada Modificação A), os
30 gradientes das 8 primeiras camadas do codificador foram congelados, restringindo a atualização de
31 pesos estritamente às 4 camadas finais e à cabeça de classificação.

```

Acurácia: 84.17%
Loss: 0.3875
Tempo de Treino: 0.72 minutos

```

Figure 1: Metricas Modelo A

32 A justificativa técnica para esta alteração arquitetural é a redução drástica da complexidade de
 33 treinamento. O congelamento diminui o processamento matemático exigido durante a propagação
 34 retroativa (*backpropagation*), poupando carga de memória e ciclos computacionais da GPU.

35 Como desdobramento direto dessa otimização de infraestrutura, introduziu-se a Modificação B.
 36 Aproveitando a eficiência computacional viabilizada pelo congelamento das camadas, a configuração
 37 da tarefa foi alterada para comportar um aumento exponencial no volume de dados de treinamento,
 38 passando de 2.000 para 20.000 amostras da base de dados. Essa expansão experimental justifica-se
 39 pela necessidade explícita de aumentar a capacidade de generalização do modelo perante dados
 40 desconhecidos.

```

Acurácia: 90.60%
Loss: 0.2519
Tempo de Treino: 4.59 minutos

```

Figure 2: Metricas Modelo B

41 3 Configuração Experimental e Resultados

42 Os experimentos foram conduzidos em uma GPU NVIDIA T4 no Google Colab, mantendo rigorosa-
 43 mente inalterados os hiperparâmetros de base (1 época, taxa de aprendizado de $2 * 10^{-5}$) e lotes
 44 de tamanho 16) para garantir a integridade da comparação. Para compor a linha de base analítica,
 45 utilizou-se o modelo original reproduzido no TPF-01, que havia atingido 87,61% de acurácia com
 46 um custo computacional de 75 segundos. O modelo sob a Modificação A foi retreinado inicialmente
 47 usando o mesmo conjunto de 2.000 amostras do TPF-01.

48 A Modificação A obteve uma acurácia de 84,17% no conjunto de validação, registrando um tempo
 49 recorde de treinamento de apenas 45 segundos. Observou-se uma queda de desempenho em relação
 50 ao TPF-01, comportamento teoricamente previsto dado que a rede foi privada de grande parte de seus
 51 graus de liberdade para moldar-se especificamente ao problema. Contudo, a redução de 40% no custo
 52 temporal atestou de forma absoluta a eficiência da limitação imposta pela arquitetura.

53 Ao submeter a Modificação B ao novo conjunto massivo de 20.000 amostras sob o mesmo regime
 54 de congelamento de camadas, o tempo de execução totalizou 271 segundos. Em contrapartida, o
 55 modelo superou as restrições arquiteturais e alcançou 90,60% de acurácia, suplantando os resultados
 56 iniciais reproduzidos no TPF-01 e aproximando-se vigorosamente dos 93,5% reportados no artigo
 57 original. A tabela de métricas e as curvas comparativas de desempenho e tempo estão devidamente
 58 documentadas na Tabela 1 e Figura ??




Figure 3: Comparação de Modelos(Acuracia e Tempo)

59 4 Discussão e Conclusão

60 A análise cruzada das métricas evidência uma compensação nítida (*trade-off*) entre tempo de treino
61 e acurácia estabelecida pelo congelamento das camadas. O isolamento da Modificação A provou
62 que reduzir a complexidade da rede otimiza severamente a velocidade de convergência, mas acarreta
63 custos na precisão quando a densidade de dados é pequena. A verdadeira efetividade das modificações
64 implementadas materializou-se na Modificação B: o alívio gerado pelo congelamento foi a chave para
65 transpor as limitações de hardware e injetar volume no treinamento, gerando um retorno expressivo
66 de generalização que compensou amplamente o tempo extra de processamento.

67 Testes interativos complementares corroboraram estes dados empiricamente. Observou-se na prática
68 que a Modificação B desenvolveu uma maior resiliência lógica frente a textos longos e estruturas
69 semânticas ruidosas ou ambíguas, solucionando classificações complexas com alta margem de
70 confiança, um feito que os modelos base e A falharam em atingir.

71 O principal aprendizado desta jornada analítica fundamenta-se na percepção de que aprimorar
72 Grandes Modelos de Linguagem na prática não se restringe apenas à arquitetura tensorial, mas ao
73 gerenciamento estratégico dos recursos computacionais disponíveis. Para trabalhos e refinamentos
74 futuros, direciona-se a investigação para a implementação de agendadores de taxa de aprendizado
75 com *warmup* ou métodos de decaimento de pesos ajustáveis, visando extrair o máximo de precisão
76 das finas camadas superiores mantendo a viabilidade estrutural do sistema. .

77 5 Citações e Referências

78 [1] Devlin, J., Chang, M.-W., Lee, K. & Toutanova, K. (2019) BERT: Pre-training of Deep Bidirectional
79 Transformers for Language Understanding. In *Proceedings of the 2019 Conference of the North American*
80 *Chapter of the Association for Computational Linguistics (NAACL)*, pp. 4171–4186.